

MODELAGEM INFORMACIONAL

Oficina de dados na AWS Academy



Júlio César Chaves

Big Data & Data Lakes

Maio, 2023

julio.cesar.chaves@prof.fgv.edu.br

AWS conta EMAP 513592933495, console em Norte de Virginia (us-east-1)

S3, bucket compartilhado



Oficina2023.1

Glue



Athena



Azure - servidor Windows de lab
191.235.80.65:53287



Power BI

E:\ArquivosCompartilhados\COVID

OPCIONAL - Desktop individual na sala de aula ou em casa (pessoal)



00 Escolha da fonte de dados

ESCOLHA DAS BASES DE DADOS

Lista de algumas fontes públicas

COVID Vacinação <https://opendatasus.saude.gov.br/dataset/covid-19-vacinacao>

PNAD (IBGE), PNAD Contínua (IBGE), PNAD-Covid (IBGE),

<https://ibge.gov.br/estatisticas/sociais/trabalho/17270-pnad-continua.html?=&t=microdados>

Censo básico, educação superior, ensino básico, Censo Demográfico (IBGE), Pesquisa Nacional de Saúde -PNS (IBGE), POF (IBGE) , PME (IBGE)

<https://www.ibge.gov.br/estatisticas/sociais/trabalho/9662-censo-demografico-2010.html?=&t=microdados>

Receita Federal, <https://www.gov.br/receitafederal/pt-br/assuntos/orientacao-tributaria/cadastros>

Censo Escolar (INEP), Censo da Educação Superior (INEP), Prova Brasil (INEP), ENEM (INEP), ENADE (INEP), Dados Públicos CNPJ (Receita Federal), Munic-Dados Municipais (IBGE), FINBRA (Siconfi).

01 conexão em novo lab

Entrada no novo Lab

URL

<https://513592933495.signin.aws.amazon.com/console>

Login

Seu número de matrícula.


Senha

*Seu número de matrícula+
"_fgv1234"*

*Troque a senha no primeiro
Login*

02 Download e pré-processamento no servidor de Lab

Ambiente de armazenamento



Use o nosso servidor de Lab

191.235.80.65:53287

Bucket da oficina

O nosso bucket de trabalho na oficina é "oficina2023.1".

Vamos baixar os arquivos desejados para o servidor de lab e comprimi-los no formato GZIP antes de carregar no S3.

Use o prompt do MobaXterm para manipular os arquivos

ARQUIVO COM “VALORES ENTRE ASPAS”

Nos arquivos originais dos dados de vacinação contra a covid-19, vemos que os valores estão entre aspas.

No momento de carregar os dados no Glue podemos informar que os valores originais estão entre aspas e mesmo assim não funciona.

Isso ocorre porque alguns atributos estão entre aspas e outros não, resultando em um padrão incompatível com a configuração básica do Glue.

Existem parâmetros do Glue que tratam as aspas

quoteChar

Uma solução é remover as aspas antes de carregar no Glue

```
sed -i 's/"/"/g' <arquivo>
```

Serde serialization lib

org.apache.hadoop.hive.serde2.OpenCSVSerde

Serde parameters

Key

Value

escapeChar

\

×

quoteChar

"

×

separatorChar

,

×

Type key...

Type value...

ARQUIVOS COM CARACTERES FORA DE PADRÃO


A base de projeção de população do censo possui várias linhas com observações entre parêntesis, dificultando a carga

```
569;Rio-Preto-da-Eva;34856↵
;Santa-Isabel-do-Rio-Negro;26566(7)↵
;Santo-Antônio-do-Içá;20889↵
;São-Gabriel-da-Cachoeira;47031↵
;São-Paulo-de-Olivença;40837↵
;São-Sebastião-do-Uatumã;14678↵
;Silves;9289↵
;Tabatinga;68502(8)↵
;Tapauá;16876(24)↵
;Tefé;59250↵
;Tonantins;19038↵
```

Existe um conceito na ciência da computação, a expressão regular ou "Regex", que provê uma forma concisa e flexível de identificar cadeias de caracteres de interesse, como caracteres particulares, palavras ou padrões de caracteres.

Existem portais on-line onde se pode testar expressões regulares. A partir da descoberta do padrão, torna-se possível eliminar a cadeia de caracteres que está impedindo a carga.

Ex.: portal [RegExp: Learn, Build, & Test RegEx](#)



PROBLEMAS DE ACENTUAÇÃO E CARACTERES ESPECIAIS

Arquivos são gerados em determinado padrão de linguagem. Ao carregar numa plataforma que possui um padrão diferente, podemos observar textos com símbolos estranhos.

nomemunicípio

Espigão D'Oeste

Guajar-Mirim

populaçõestimada

Há solução.

1) descobrir o padrão de linguagem do seu arquivo de origem. Isso pode ser feito através de um comando no Linux:

```
file -bi ProjecaoPOP2021.CSV
```

```
text/plain; charset=iso-8859-1
```

2) sabendo o padrão de origem, podemos converter ao padrão de destino. Isso também pode ser feito através de um comando no Linux.

```
iconv -f iso-8859-1 -t UTF8  
ProjecaoPOP2021.CSV >  
ProjecaoPOP2021.utf8.csv
```

Após rodar novamente a carga...

nomemunicípio

Espigão D'Oeste

Guajará-Mirim

populaçãotestimada

03 Upload em um bucket S3

Observe a estrutura das pastas, estamos no mesmo ambiente

Vamos carregar os nossos dados sempre no formato GZIP. Pois gasta menos, custa menos, e roda tudo mais rápido, inclusive a transferência dos dados.

Amazon S3 > Buckets > oficina2023.1 > covid/ > rs/

rs/

☐	Nome
☐	 part-00000-849dbb6d-94b9-4c43-9623-d0ae3122be9a.c000.csv.gz
☐	 part-00001-849dbb6d-94b9-4c43-9623-d0ae3122be9a.c000.csv.gz
☐	 part-00002-849dbb6d-94b9-4c43-9623-d0ae3122be9a.c000.csv.gz
☐	 part-00003-849dbb6d-94b9-4c43-9623-d0ae3122be9a.c000.csv.gz
☐	 part-00004-849dbb6d-94b9-4c43-9623-d0ae3122be9a.c000.csv.gz

outras pessoas acessarem seus objetos



 Carregar

04 Catálogo no Glue

CATALOGAR NO GLUE

Services

 **AWS Glue** ☆
AWS Glue is a fully managed

Top features
[AWS Glue Studio](#) [Data Catalog](#)

 **AWS Glue DataBrew** ☆
Visual data preparation tool

 **AWS Signer** ☆
Ensuring trust and integrity of

 **AWS AppConfig** ☆

AWS Glue

▼ Data Catalog

Databases [New](#)

Tables [New](#)

Stream schema registries

Schemas

Connections  [New](#)

Crawlers [New](#)

Classifiers [New](#)

Catalog settings

▼ Data Integration and ETL

AWS Glue Studio

Jobs  [New](#)

Interactive Sessions

ber 6, 2022 at 11:01:32 (UTC)

Create crawler

< 1 > 

able changes from last ...

updated

CATALOGAR NO GLUE

Step 1/5

Set crawler properties

Crawler details [Info](#)

Name

197990112 - rs

Name can be up to 255 characters long. Some control characters are prohibited.

Description - optional

Enter a description

Descriptions can be up to 2048 characters long

Data source configuration

Is your data already mapped to Glue tables?



Not yet

Select one or more data sources to be crawled.



Yes

Select existing tables from your Glue Data Catalog.

Data sources (0) [Info](#)

The list of data sources to be scanned by the crawler.

Edit

Remove

Add a data source

Data source

Choose the source of data to be crawled.

S3

Network connection - optional

Optionally include a Network connection to use with 1 one Network connection so any other S3 targets will be blank).

Clear selection

Add new connection

Location of S3 data



In this account



In a different account

S3 path

Browse for or enter an existing S3 path.

Q s3://oficina2023.1/covid/rs X

All folders and files contained in the S3 path are crawled to crawl all objects in MyFolder within MyBucket.

Subsequent crawler runs

This field is a global field that affects all S3 data sources



Crawl all sub-folders

Crawl all folders again with every subsequent crawler

Cancel

Add an S3 data source

CATALOGAR NO GLUE

Step 3/5

Configure security settings

IAM role [Info](#)

Existing IAM role

AWSGlueServiceRole-oficina2023.1 ▼

Create new IAM role

Update role

Only IAM roles created by the AWS Glue console and named "AWSGlueServiceRole-" can be updated.

Lake Formation configuration - optional

Allow the crawler to use Lake Formation credentials to access the data source. [Learn more.](#) [🔗](#)

- ☐ Use Lake Formation credentials for crawling
- Checking this box will allow the crawler to use Lake Formation credentials for crawling the data source. If the crawler is in another account, you must provide the registration ID. Otherwise, the crawler will crawl only those data sources that are accessible to the crawler's role.

Step 4/5

Set output and scheduling

Output configuration [Info](#)

Target database

oficina2023.1

Clear selection

Add database

Table name prefix - optional

197990112

Maximum table threshold - optional

This field sets the maximum number of tables the crawler will generate. In the event that this number is surpassed, the crawler will automatically stop with an error. If not set, the crawler will automatically generate a number of tables depending on the data schema.

Type a number greater than 0


► Advanced options

s

Create crawler

RODAR O CRAWLER NO GLUE


Acompanhe a execução .



Duration	Status	DPU hours	Table changes
43 s	Completed	0.072	1 table change, 0 partitions
59 s	Completed	0.056	1 table change, 0 partitions
56 s	Completed	0.044	1 table change, 0 partitions

CATALOGAR NO GLUE

Valide a execução através do log



Valide a sua nova tabela dentro do seu banco de dados

AWS Glue

▼ Data Catalog

Databases [New](#)

Tables [New](#)

Stream schema registries

Schemas

Connections [New](#)

AWS Glue > Tables

Tables

A table is the metadata definition that represents your data, including its schema. A table can be used as a source or target

Tables (1)

View and manage all available tables.

☐	Name ▲	Database ▼	Location
☐	197990112rs	oficina2023.1	s3://oficina2023.1/covid/rs/

05 Consulta no Athena

LER BASE DE DADOS NO ATHENA

Escolha um local para cache de dados, `s3://oficina2023.1/cache-athena/`

Search results for 'athena'

Services

 **Athena** ☆
Query Data in S3 using SQL

Features

 **Tag Editor**
Resource Groups & Tag Editor fea

Create Amazon WorkMail org

Data

Data source
AwsDataCatalog ▼

Database
oficina2023.1 ▼

Tables and views Create ▼ ⚙️

🔍 Filter tables and views

▼ **Tables (1)** < 1 >

🔍 197990112rs ⋮

▶ **Views (0)** < 1 >

Manage settings

Query result location and encryption

Location of query result - *optional*

Enter an S3 prefix in the current region where the query result

🔍 `s3://oficina2023.1/cache-athena/`

LER BASE DE DADOS NO ATHENA

Amazon Athena > Query editor

Editor | Recent queries | Save

Query result and encryption

Query result location and encryption

Query result location
<s3://macropub/adm-athena-cache/> 

Query 1 : X |  Query 2 : X

```
1 SELECT count(*) FROM "oficina2023.1"."197990112rs";
```

Query results | Query stats

 Completed

Results (1)

#	_col0
1	23691684

06 Visualização no PowerBI


Instalar o Simba Athena

Já está instalado em nosso servidor de laboratório.

Connecting to Amazon Athena
with ODBC - Amazon Athena

Criar uma conexão ODBC 64

Necessário fazer no seu perfil



Criar uma conexão ODBC 64

 Simba Athena ODBC Driver DSN Setup ✕

Data Source Name:

Description:

AWS Region:

Catalog:

Schema:

Workgroup:

Metadata Retrieval Method:

Output Options

S3 Output Location:

Encryption Options:

KMS Key:

Endpoint Override:

Streaming Endpoint Override:


v1.1.17.1001 (64 bit)

Criar uma conexão ODBC 64

Authentication Options

AKIAXPFEGHR3SAT37N7L

QM3snN32kCUBXJ0KyUIS8AXJr9quqlhSwjrkBaQN



The 'Authentication Options' dialog box is shown. It has a title bar with a red warning icon and a close button. The 'Authentication Type' is set to 'IAM Credentials'. The 'User' field contains 'AKIAXPFEGHR3SAT37N7L'. The 'Password' field is masked with dots. There is a 'Password Options...' button next to the password field. The 'Session Token' field is empty.

Authentication Options


Authentication Type: IAM Credentials

User: AKIAXPFEGHR3SAT37N7L

Password: [Masked]

Session Token:

Password Options...



The 'Test Results' dialog box is shown. It has a title bar with a red warning icon and a close button. The 'Test Results' section contains the following text: 'SUCCESS!', 'Successfully connected to data source!', 'ODBC Version: 03.80', 'Driver Version: 1.1.17.1001', 'Bitness: 64-bit', and 'Locale: en_US'. There is an 'OK' button at the bottom.

Test Results

SUCCESS!


Successfully connected to data source!

ODBC Version: 03.80
Driver Version: 1.1.17.1001
Bitness: 64-bit
Locale: en_US

OK

Authentication Options... Advanced Options... Logging Options...


No Power BI




Obter Dados



De ODBC



Navegador



Usuário =

AKIAXPFEGHR3SAT37N7L


Senha =

QM3snN32kCUBXJ0KyUIS8AXJr9quqlhSwjrKBaQN

Crie a sua visualização

Primeiro problema de BigData

*O Volume de 23 milhões de linhas não escala no Power BI.
Se clicar em "Carregar" fica um dia lendo a tabela.*



*Clicar diretamente em "transformar". Elaborar uma agregação
por "vacina_descricao_dose".*

Quantidade de vacinas por descrição da dose (RS)

