MODELAGEM INFORMACIONAL

Instruções para trabalho de pipeline de dados

FGV EMAp

Júlio César Chaves

julio.cesar.chaves@prof.fgv.edu.br

Outubro, 2025

Guia

O trabalho está composto em duas partes:

Parte I

Preencher a visão de alto nível de um pipeline de dados para uma pergunta definida.

Parte II

Dois slides com texto dissertativo compartilhando uma reflexão sobre os V's do Big Data relacionados ao quadro preenchido na ***Parte I****.*

Você está recebendo:

A URL da DATA.RIO que descreve e disponibiliza os dados que foram usados para montar este exercício.

A pergunta:

Cenário Real

O turismo marítimo representa uma parcela importante do turismo internacional no Rio de Janeiro. Em 2019, dos 6,3 milhões de turistas internacionais que chegaram ao Brasil, 123.127 desembarcaram por via marítima. O Rio de Janeiro liderou o ranking de chegadas por mar com 53.745 turistas estrangeiros. A temporada de cruzeiros 2024/2025 no Rio recebeu mais de 327 mil visitantes no Pier Mauá, com 36 navios (25 internacionais e 11 nacionais), totalizando 107 atracações. Esse crescimento expressivo demonstra a importância de uma análise de dados robusta para o planejamento do setor.

Pergunta de Negócio

Quais são os principais mercados emissores de turistas (países de origem) por via marítima para o Rio de Janeiro e qual é a sazonalidade dessas chegadas?

Como essas informações podem orientar estratégias de marketing internacional e planejamento da infraestrutura portuária?

Subquestões para Análise

Quais continentes e países representam os maiores volumes de turistas por via marítima? Existe sazonalidade significativa nas chegadas? Em quais meses há picos e vales? Como a origem geográfica dos turistas se relaciona com os padrões mensais de chegada? Que recomendações podem ser feitas para campanhas de marketing direcionadas? Como otimizar a alocação de recursos da infraestrutura portuária ao longo do ano?

A rúbrica

Critérios objetivos distribuídos em 5 dimensões principais:

Parte I - Visão em alto nível do pipeline de dados – 50%

0 - Insuficiente – não descreveu nenhuma fonte ou transformação que respondesse a pergunta.

30% - Básico – considerou uma fonte e uma transformação para responder a pergunta.

40% - Proficiente – considerou no mínimo 3 fontes, +3 transformações para responder a pergunta.

50% Avançado – considerou +3 fontes, +5 transformações, respondendo a pergunta de forma plena, inclusive cobrindo as sugestões de análise.

Parte II – Reflexões Big data vs cenário de negócio – 50%

0 - Insuficiente – não refletiu, apresentou texto desconexo ou feito pelo GPT.

30% - Básico – cumpriu a tarefa de forma superficial.

40% - Proficiente – apresentou um texto bem elaborado, estruturado e sem erros de português.

50% Avançado – além de ser proficiente, agregou exemplos expandidos conectados ao mesmo tema.

Parte I

Visão em alto nível do pipeline de dados



2. Que dados suportam essa descoberta?

1. O que está tentando descobrir?



Quais bases de dados estão disponíveis para responder a pergunta?

Quais técnicas vou usar para responder a pergunta?

Qual é a resposta à pergunta?

Entrada	*Transformação*	*Saída*

Parte II

Guia para Reflexão: os elementos de uma atividade de dados conectados aos V's do Big Data

Quais insights podem ser extraídos dos dados?	*Quão precisos e confiáveis são os dados?*	*Quais tipos e formatos? Quantas fontes diferentes de dados?*	*Qual a frequência de novos dados sendo gerados e ingeridos?*	*Qual o tamanho do conjunto de dados? Quantos novos dados são gerados?*
Valor	*Veracidade*	*Variedade*	*Velocidade*	*Volume*
Que detalhes você sabe sobre os dados (por exemplo, campos e tipos de campo)? *Que tipo de análise e quanto processamento pode ser necessário para obter insights?*	*Que tipo de leis de privacidade podem afetar a coleta e retenção de dados em diferentes geografias e setores?* *Que tipo de limpeza e transformações podem ser necessárias para usar esses dados?*	*Com que rapidez os dados ficariam obsoletos?* *Como essa fonte de dados será combinada com outras fontes de dados?*	*O volume de dados que é ingerido no pipeline estaria em nível constante ou seria intermitente? Os padrões são previsíveis?* *Os dados precisam ser processados e analisados quase em tempo real para serem valiosos?*	*Qual seria o volume geral e a velocidade dos dados recebidos? Como os dados podem ser transferidos para o seu sistema (por exemplo, FTP ou um dispositivo conectado)?*

© 2022, Amazon Web Services, Inc. or its affiliates. All rights reserved.

De forma relacionada ao cenário descrito no pipeline de dados, compartilhe uma reflexão sobre Valor, Veracidade e Variedade

Use esse tamanho de fonte e ocupe apenas esse bloco

De forma relacionada ao cenário descrito no pipeline de dados, compartilhe uma reflexão sobre Velocidade e Volume

Use esse tamanho de fonte e ocupe apenas esse bloco